

Predição de Risco de Crédito Utilizando Técnicas de Machine Learning

Classificação binária aplicada à concessão de crédito com base em dados históricos de clientes.

Bruno Gonçalves Faria, Saulo Klein Nery e Sebastião Gonçalves Ferreira Neto

Centro Federal de Educação Tecnológica Celso Suckow da Fonseca – CEFET/RJ – Campus Nova Friburgo, Nova Friburgo, RJ, Brasil

TÉCNICAS DE APRENDIZADO DE MÁQUINA

Objetivo do Trabalho

Desenvolver e comparar modelos de classificação para **predição de risco de crédito**, avaliando desempenho com métricas padronizadas e validação cruzada.

→ Aplicar seis algoritmos de ML supervisionado

→ Comparar desempenho com métricas objetivas

→ Identificar a técnica mais adequada ao problema

Contexto e Motivação

A concessão de crédito envolve risco de inadimplência. Instituições financeiras buscam modelos preditivos que reduzam perdas e apoiem decisões mais seguras e eficientes.

Problema central

Classificar clientes em **aprovado** ou **não aprovado** com base em características financeiras e comportamentais.

Relevância

Modelos automatizados aumentam a escala, a consistência e a objetividade das análises de crédito.

Base de Dados

Dados públicos do **Kaggle**, amplamente utilizados em pesquisas de crédito. Estrutura tabular com variáveis numéricas e categóricas.

5.001

Registros de clientes


9

Atributos preditores

1


Variável alvo binária

Preparação dos Dados



Os dados passaram por tratamento de ausentes, balanceamento de classes, codificação das variáveis categóricas e padronização quando necessário, antes da divisão em treino e teste na proporção de 75% / 25%.

Fluxo Metodológico



Algoritmos Utilizados



KNN

Classificação por proximidade a vizinhos mais próximos no espaço de atributos.




Decision Tree

Árvore de decisão com divisões recursivas baseadas nos atributos mais informativos.



SVM

Busca o hiperplano ótimo que maximiza a margem entre as classes.



Naive Bayes

Classificador probabilístico baseado no teorema de Bayes com independência condicional.



Random Forest


Conjunto de árvores de decisão utilizado para melhorar a estabilidade e o desempenho do modelo.



ANN

Rede neural artificial com camadas ocultas para identificação de padrões nos dados.

Random Forest – Feature Importance




Variáveis mais importantes

- CreditScore
- EmploymentType (Self-Employed, Salaried, Unemployed)
- Income

Variáveis menos importantes

- City
- Education (PhD, Masters, Bachelors, High School)
- Gender

Mapa de calor da correlação entre as variáveis



1

EmploymentType tem forte relação com Income, LoanAmount e CreditScore


2

Variáveis financeiras têm mais relação com a LoanApproved

3

Baixa correlação não significa irrelevância

Redes Neurais – Neurônios da primeira camada



1

Income e CreditScore apresentam mais influências nos neurônios

2

Education, Gender e City apresentam pesos constantes devido a possível baixa importância

Métricas de Avaliação

Utilizou-se um conjunto complementar de métricas para avaliação abrangente do desempenho dos classificadores.

Acurácia

Proporção de previsões
corretas no total

Precisão e Recall

Avaliam erros e acertos por
classe


F1-Score

Média harmônica entre
precisão e recall

Validação Cruzada

k-fold para estimativa
robusta de generalização


Resultados — Acurácia por Algoritmo



Random Forest e **Decision Tree** destacaram-se com as maiores acurácias. Técnicas baseadas em árvores superaram consistentemente os demais classificadores.

Algoritmo	Acurácia
Random Forest	95,49%
Decision Tree	95,31%
ANN	93,92%
SVM	90,28%
Naive Bayes	87,85%
KNN	86,63%

Resultados da Validação Cruzada




Os resultados da validação cruzada confirmam a robustez dos modelos baseados em árvores, com pequena variação em relação ao conjunto de teste.

Algoritmo	CV k-fold
Random Forest	94,66%
Decision Tree	94,66%
ANN	90,70%
SVM	89,57%
Naive Bayes	86,23%
KNN	85,49%

Random Forest e Decision Tree demonstraram maior capacidade de generalização, confirmando-se como as técnicas mais adequadas para predição de risco de crédito neste conjunto de dados.

Comparação das Métricas Médias na Validação Cruzada

Decision Tree e Random Forest apresentaram os melhores resultados gerais, mantendo desempenho superior nas principais métricas avaliadas.



Discussão dos Resultados

Os resultados indicam que o pré-processamento e a escolha do modelo tiveram impacto direto no desempenho final.



Modelos baseados em árvores tiveram melhor desempenho.



Random Forest e Decision Tree ficaram tecnicamente empatados na validação cruzada.



O balanceamento e o pré-processamento impactaram diretamente os resultados.



Redes Neurais e SVM tiveram bom desempenho, mas abaixo dos modelos de árvores.

Conclusão

Este estudo alcançou seus objetivos, demonstrando a aplicação bem-sucedida de modelos de Machine Learning na predição de risco de crédito e identificando as abordagens mais eficazes.

1 Objetivo Alcançado

O projeto desenvolveu e comparou modelos de classificação para predição de risco de crédito com sucesso, avaliando o desempenho dos modelos.

95.49%

Acurácia

No teste inicial

2 Modelos de Destaque

Os algoritmos de **Decision Tree** e **Random Forest** apresentaram consistentemente os melhores desempenhos nas métricas avaliadas.

3 Destaque do Random Forest

O **Random Forest** destacou-se como a técnica mais adequada para este problema, apresentando melhor desempenho geral considerando teste inicial e validação cruzada.

94.66%

Acurácia média

Na validação cruzada

Trabalhos Futuros

1

Testar novas configurações de hiperparâmetros.

2

Avaliar outras técnicas de balanceamento.

3

Explorar diferentes formas de transformar variáveis categóricas.

4

Aplicar o estudo em bases maiores.

5

Comparar os resultados com dados reais de instituições financeiras.